Manuel-Toplama Hariç Test Metrikleri — Üç Senaryo Analizi

Hocanın Geri Bildirimi (Mayıs 2026 sunum sonrası):

> *"Test setinden manuel_toplama örneklerini çıkararak metrikleri tekrar raporlayın. Özellikle şu üç sonucu görmek istiyorum: 1) Manuel_toplama dahil test sonucu, 2) Manuel_toplama hariç test sonucu, 3) Sadece doğal kullanıcı yorumlarında nötr sınıf performansı."*

1. Yöntem

Multi-seed final eğitim sırasında üretilen `test_predictions.csv` dosyaları post-hoc filtreleme ile yeniden değerlendirilmiştir; modelin yeniden eğitilmesi **gerekmemiştir**. Filtreleme `source` sütunu üzerinden uygulanmıştır.

Modeller: BERTurk, ELECTRA-tr (her biri 3 seed: 42, 43, 44) **Doğal kullanıcı tanımı:** `source ∈ {otelpuan.com, neredekal, otelpuan_otelyorum}` (manuel_toplama hariç).

2. Senaryo 1 vs Senaryo 2 — Genel Karşılaştırma

Model	Senaryo	n_test	Accuracy	Macro-F1	F1-nötr	F1-negatif	F1-pozitif
BERTurk	Manuel **dahil**	1393	0.8857 ± 0.0066	0.8797 ± 0.0073	0.8056 ± 0.0112	0.9047 ± 0.0111	0.9286 ± 0.0026
BERTurk	Manuel **hariç**	1249	0.8724 ± 0.0080	0.8428 ± 0.0118	0.6950 ± 0.0233	0.9047 ± 0.0111	0.9286 ± 0.0026
ELECTRA-tr	Manuel **dahil**	1393	0.8906 ± 0.0130	0.8853 ± 0.0143	0.8143 ± 0.0243	0.9094 ± 0.0186	0.9321 ± 0.0016
ELECTRA-tr	Manuel **hariç**	1249	0.8780 ± 0.0140	0.8510 ± 0.0175	0.7116 ± 0.0331	0.9094 ± 0.0186	0.9321 ± 0.0016

Senaryo Δ (Hariç − Dahil)

Model	Δ Accuracy	Δ Macro-F1	Δ F1-nötr
BERTurk	-0.0132	-0.0369	-0.1106
ELECTRA-tr	-0.0126	-0.0342	-0.1027

3. Senaryo 3 — Sadece Doğal Kullanıcı Nötr Sınıf Performansı

Manuel_toplama hariç tutulan ve sadece doğal kullanıcı yorumları üzerinden nötr sınıfı için precision / recall / F1 değerleri:

Model	n_doğal	n_nötr_gerçek	Recall-nötr	Precision-nötr	F1-nötr
BERTurk	1249	281	0.6302 ± 0.0462	0.7770 ± 0.0166	0.6950 ± 0.0233
ELECTRA-tr	1249	281	0.6573 ± 0.0346	0.7757 ± 0.0314	0.7116 ± 0.0331

4. Yorumlama

Senaryo 1 (manuel dahil) ↔ Senaryo 2 (manuel hariç) farkı:

Manuel_toplama satırlarının (test setinde 142 satırın tamamı nötr etiketli) test setinden çıkarılması durumunda, F1-nötr değerinde belirgin bir düşüş gözlenmektedir. Bu düşüşün nedeni manuel_toplama örneklerinin yapı-temelli yazımı sayesinde modelin **karşıtlık bağlacı + karma duygu** sinyalini öğrenmiş olmasıdır. Doğal kullanıcı yorumlarında nötr sınıfı yapısal olarak daha gürültülü bir dağılıma sahiptir (rating-based etiket gürültüsü; final tez raporu §5.2 Bulgu D).

Senaryo 3 (doğal kullanıcı nötr odak):

Doğal kullanıcı yorumları üzerinde nötr sınıfı için elde edilen F1 değeri, rating-based etiketleme yönteminin yapısal sınırını yansıtır. Modelin nötr sınıfı için verdiği yüksek precision (yüksek hassasiyet) düşük recall ile birleştiğinde **konservatif tahmin davranışı** ortaya çıkar: model nötr olduğunu söylediğinde haklıdır, ancak gerçek nötrlerin önemli bir kısmını pozitif veya negatif olarak sınıflandırmaktadır. Bu, kullanıcının 3 yıldız vermiş olmasına rağmen yorum metninin objektif olarak pozitif veya negatif baskın olduğu durumlarda matematiksel olarak savunulabilir bir karardır.

5. Tekrarlanabilirlik

```
python src/manuel_excluded_metrics.py
```

Çıktılar: - `reports/manuel_excluded/multi_seed_3_scenarios.csv` (model × seed × senaryo) - `reports/manuel_excluded/multi_seed_3_scenarios_summary.csv` (aggregat) -

```
reports/manuel_excluded/natural_notr_per_seed.csv -
reports/manuel_excluded/natural_notr_summary.csv - reports/manuel_excluded/summary.json
```